

Contexto

IMPLEMENTACIÓN DE UN SISTEMA DE VISIÓN ARTIFICIAL PARA ASISTIR EN LA DETECCIÓN DE COVID-19

PREENTREGA – Trabajo Integrador Final

Diplomatura en Inteligencia Artificial – UTN

Autores: Pablo Salera, Alejandro García, Mirta Beatriz Arce, Mariano Buonifacino, Vanesa Galvagno.

Institución: Centro de Diagnóstico por Imágenes

1. Resumen Ejecutivo

El presente proyecto propone el desarrollo de un sistema de visión artificial basado en redes neuronales para asistir en la detección de COVID-19 a partir de radiografías de tórax. El objetivo principal es analizar la viabilidad técnica, ética y operativa de implementar este tipo de herramientas en un Centro de Diagnóstico por Imágenes, complementando el trabajo clínico habitual de los especialistas.

El problema surge ante la necesidad de agilizar el proceso diagnóstico, especialmente en contextos de alta demanda, y de contar con herramientas de apoyo que permitan identificar patrones compatibles con patologías respiratorias de forma rápida y consistente. La propuesta consiste en entrenar un modelo de clasificación de imágenes utilizando datasets públicos y anónimos disponibles para investigación, de modo que el sistema pueda diferenciar casos normales de casos con signos compatibles con COVID-19.

El impacto esperado incluye una reducción del tiempo de revisión preliminar, la estandarización de criterios visuales, la mejora del flujo de trabajo interno y un apoyo confiable al diagnóstico médico. Este proyecto no reemplaza decisiones médicas, sino que funciona como un sistema de apoyo al diagnóstico (CAD).

Es importante destacar que la radiografía de tórax no permite diagnosticar COVID-19 de manera definitiva. Su utilidad se manifiesta principalmente en fases avanzadas de la enfermedad, cuando pueden observarse patrones pulmonares característicos. Por lo tanto, su interpretación siempre debe complementarse con pruebas virales (como PCR o test de antígeno), manteniendo su rol exclusivamente como método auxiliar dentro del proceso diagnóstico.

2. Problema y Objetivos del Proyecto

Problema identificado

Durante la pandemia, los centros de diagnóstico enfrentaron altos volúmenes de estudios radiológicos. Incluso hoy, los síntomas respiratorios siguen siendo frecuentes, lo cual genera sobrecarga del personal, demoras en la lectura de informes y variabilidad en la interpretación inicial. La IA permite contribuir como cribado inicial, alertando sobre imágenes que requieren atención prioritaria.

Objetivo general

Desarrollar un sistema de visión artificial capaz de clasificar radiografías de tórax en dos categorías: normal y compatible con COVID-19, como apoyo al diagnóstico médico.

Objetivos específicos

- Entrenar un modelo de aprendizaje supervisado basado en una red neuronal convolucional (CNN), con imágenes radiográficas etiquetadas por diagnóstico.
- Utilizar datasets públicos y anónimos.
- Evaluar la capacidad del modelo para identificar patrones pulmonares.
- Analizar la viabilidad de implementación en un centro real.
- Considerar aspectos éticos, privacidad y supervisión humana.

3. Viabilidad de Datos e Información

Disponibilidad de datos

Se utilizarán datasets públicos como COVID-19 Radiography Database, COVIDx y otros conjuntos educativos autorizados. Todos están anonimizados y listos para investigación.

Aspectos técnicos

El proyecto puede desarrollarse con Google Colab, TensorFlow/Keras, y modelos preentrenados como MobileNetV2 o ResNet50. El sistema se integraría como soporte, nunca como sustituto de la lectura profesional.

Participación humana

Los radiólogos supervisan los resultados y validan predicciones. La IA funciona como recomendador, manteniendo siempre la autonomía médica.

Cuestiones éticas

- No se usan datos reales del centro.
- No se almacenan datos sensibles.
- Supervisión obligatoria.
- Revisión de sesgos del dataset.

4. Plan de Medición del Éxito

Indicadores técnicos

- Capacidad del modelo para identificar patrones pulmonares.
- Consistencia y estabilidad frente a imágenes nuevas.
- Comportamiento adecuado en condiciones variadas.

Indicadores operativos

- Reducción del tiempo de revisión preliminar.
- Optimización del flujo interno.
- Menor carga cognitiva en períodos de alta demanda.

Indicadores clínicos

- Mejora en la priorización de casos sospechosos.
- Detección temprana de imágenes patológicas.

- Fácil integración al trabajo médico sin interrumpir procesos.

5. Riesgos Principales Identificados

Riesgos técnicos

- Falsos positivos o falsos negativos.
- Sesgos en el dataset.
- Diferencias entre imágenes del dataset y del centro real.

Riesgos humanos

- Dependencia excesiva del sistema.
- Interpretación incorrecta sin supervisión profesional.

Riesgos éticos

- Uso como sustituto del diagnóstico.
- Expectativas no realistas sobre la precisión.

Estrategias de mitigación

- Supervisión médica permanente.
- Validación continua del modelo.
- Entrenamientos internos para el uso correcto.
- Comunicación clara de limitaciones y alcances.

6. Conclusión

El proyecto demuestra que la visión artificial puede convertirse en una herramienta valiosa de apoyo al diagnóstico en un centro de imágenes.

La detección automática de posibles signos compatibles con COVID-19 permite agilizar la revisión inicial, optimizar recursos y priorizar los casos que requieren atención urgente.

Si bien no reemplaza el criterio médico, la IA aporta consistencia, velocidad y respaldo analítico.

La combinación de datos públicos, herramientas accesibles y supervisión profesional convierte al proyecto en una solución viable, escalable y alineada con buenas prácticas éticas y técnicas.

Estrategia

La mejor estrategia de entrenamiento de *deep learning* para este proyecto es, sin duda, el **Aprendizaje por Transferencia (Transfer Learning)** con un proceso de **Ajuste Fino (Fine-Tuning)**.

Esta estrategia es la más efectiva porque los datasets de imágenes médicas suelen ser relativamente pequeños, y entrenar una Red Neuronal Convolutacional (CNN)² muy profunda desde cero podría llevar a un sobreajuste (overfitting).

Aquí te presento un plan detallado basado en esa estrategia, alineado con tu documento.



Estrategia Recomendada de Entrenamiento

1. Preparación de Datos (El Set de Datos)

Dado que el archivo zip estaba vacío, deberás usar los datasets públicos que mencionaste, como **COVID-19 Radiography Database** o **COVIDx**.

- **División (Split):** Divide tu conjunto de datos en tres partes:
 - **Entrenamiento (Train):** 70-80% de los datos. El modelo "aprende" de estas imágenes.
 - **Validación (Validation):** 10-15% de los datos. Se usa *durante* el entrenamiento para evaluar el modelo después de cada época (epoch) y evitar el sobreajuste.
 - **Prueba (Test):** 10-15% de los datos. Se mantiene *completamente separado* y solo se usa una vez al final para evaluar el rendimiento real del modelo en datos nunca vistos.
- **Aumento de Datos (Data Augmentation):** Esta es la técnica más importante para "maximizar el uso del set de datos". Consiste en crear nuevas imágenes de entrenamiento aplicando transformaciones leves a las existentes (rotaciones pequeñas, zoom, desplazamientos, volteo horizontal).
 - **Beneficio:** Hace que el modelo sea más robusto y ayuda a mitigar los sesgos del dataset y las diferencias con las imágenes del centro real.

2. El Modelo: Aprendizaje por Transferencia (Transfer Learning)

Esta es la parte central de la estrategia. En lugar de construir una CNN desde cero, utilizamos un modelo preentrenado que ya ha aprendido a identificar características (bordes, texturas, formas) de millones de imágenes.

- **Modelo Base:** Carga un modelo preentrenado como **ResNet50** o **MobileNetV2** (como mencionaste), con los pesos aprendidos del dataset "ImageNet".
- **Congelar la Base:** Inicialmente, "congelas" todas las capas del modelo base. Esto significa que sus pesos no se actualizarán durante el entrenamiento. Queremos conservar todo el conocimiento que ya tiene.
- **Añadir una "Cabeza" de Clasificación:** Elimina la capa superior original del modelo (que clasificaba 1000 objetos) y añade tus propias capas en la parte

superior. Para tu problema de clasificación binaria ("Normal" vs. "COVID-compatible"), esto sería:

1. Una capa `GlobalAveragePooling2D` (para aplanar las características).
2. Una capa `Dense` (totalmente conectada) con activación `ReLU`.
3. Una capa `Dropout` (para regularización y evitar la dependencia excesiva).
4. Una capa `Dense` final con **1 neurona** y activación `sigmoid`, que dará la probabilidad de 0 (Normal) a 1 (COVID).

3. Proceso de Entrenamiento en Dos Fases

Esta es la forma "correcta" de implementar el *transfer learning*.

Fase 1: Entrenamiento de la "Cabeza"

- Con la base convolucional *congelada*, entrena el modelo.
- **Objetivo:** Solo se entrenarán las nuevas capas que añadiste. Esto permite que tu clasificador aprenda a usar las características que el modelo base está extrayendo.
- **Compilador:** Usa el optimizador `Adam` y la función de pérdida `binary_crossentropy`.

Fase 2: Ajuste Fino (Fine-Tuning)

- Una vez que el rendimiento de la "cabeza" se estabilice, *descongela* las últimas capas del modelo base (por ejemplo, el último bloque de ResNet50).
- **Objetivo:** Ahora permitirás que el modelo ajuste ligeramente sus características de alto nivel (que ya eran buenas) para que se especialicen aún más en reconocer patrones pulmonares.
- **Punto Clave:** Debes usar una **tasa de aprendizaje (learning rate) muy baja**. Esto es crucial para no destruir los pesos bien aprendidos de la Fase 1.

4. Evaluación (Medición del Éxito)

Como mencionas en tu plan, la evaluación es clave. Para un problema médico, la "Precisión" (Accuracy) no es suficiente, especialmente si los datos están desbalanceados.

- **Métricas Clave:**
 - **Matriz de Confusión:** Es la mejor herramienta. Te mostrará visualmente los **Falsos Positivos y Falsos Negativos**, que son tu riesgo técnico principal.
 - **Sensibilidad (Recall):** ¿Qué porcentaje de los casos *reales* de COVID-19 pudo detectar el modelo? (Mitiga el riesgo de falsos negativos).
 - **Precisión (Precision):** De todas las veces que el modelo dijo "COVID", ¿cuántas acertó? (Mitiga el riesgo de falsos positivos).
 - **Curva ROC y AUC:** Excelente para medir el rendimiento general del clasificador.

Esta estrategia aprovecha al máximo un conjunto de datos limitado, se alinea perfectamente con las herramientas que planeas usar (TensorFlow/Keras) y aborda directamente los riesgos de sesgo y sobreajuste.

Front end

Se espera un front con tres secciones, una donde se puedan ajustar los valores de entrenamiento , pesos ,etc y se dispare el proceso de entrenamiento

segunda donde ver las graficas relacionadas al entrenamiento y test

Métricas Clave:

- **Matriz de Confusión:** Es la mejor herramienta. Te mostrará visualmente los **Falsos Positivos y Falsos Negativos**, que son tu riesgo técnico principal.
- **Sensibilidad (Recall):** ¿Qué porcentaje de los casos *reales* de COVID-19 pudo detectar el modelo? (Mitiga el riesgo de falsos negativos).
- **Precisión (Precision):** De todas las veces que el modelo dijo "COVID", ¿cuántas acertó? (Mitiga el riesgo de falsos positivos).
- **Curva ROC y AUC:** Excelente para medir el rendimiento general del clasificador.

Donde este integrado el uso de gemini como ia generativa para analizar los datos de las graficas en su totalidad y , arme un informe de ajustes de pesos o mejoras al modelo

end donde se puedan ver las gráficas relacionadas al entrenamiento

3 Una de test donde se le pueda subir una imagen y realizar el diagnostico, donde se complementa la decision con la imagen de la radiografia con el mapa de calor mencionado , para que el medico vea donde se focalizo el modelo para decidir

De esta manera hacer auditabile el sistema